ICS 35.240
CCS L 70

中华人民共和国国家标准

GB/T 48073—2026

人工智能　深度学习框架功能要求

Artificial intelligence—Functional requirements of deep learning framework

2026-08-28 发布　　2026-12-01 实施

国家市场监督管理总局
国家标准化管理委员会　发布

目　　次

前言 …… Ⅲ
1　范围 …… 1
2　规范性引用文件 …… 1
3　术语和定义 …… 1
4　缩略语 …… 2
5　功能架构 …… 3
6　训练功能 …… 3
7　推理功能 …… 5
8　模型功能 …… 5
9　算子库功能 …… 7
10　深度学习算法 …… 7
11　应用编程接口功能 …… 7
参考文献 …… 9

前　言

本文件按照GB/T 1.1—2020《标准化工作导则　第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由全国信息技术标准化技术委员会(SAC/TC 28)提出并归口。

本文件起草单位：中国电子技术标准化研究院、北京百度网讯科技有限公司、华为技术有限公司、上海商汤智能科技有限公司、北京旷视科技有限公司、北京大学、清华大学、北京智源人工智能研究院、中国移动通信集团有限公司、中国民航信息网络股份有限公司、中移九天人工智能科技(北京)有限公司、昆仑数智科技有限责任公司、中国科学院软件研究所、浪潮云信息技术股份公司、中国科学院工业人工智能研究所、中国南方电网有限责任公司超高压输电公司、华北电力科学研究院有限责任公司、中国汽车技术研究中心有限公司、中车沈阳机车车辆有限公司、同方知网数字科技有限公司、浪潮电子信息产业股份有限公司、浙江大华技术股份有限公司、杭州海康威视数字技术股份有限公司、深圳市优必选科技股份有限公司、南京国通智能科技有限公司。

本文件主要起草人：董建、徐洋、宋文林、张军、马艳军、胡晓光、于佃海、杨恒、张行程、陈其友、刘佳、曾炜、李影、穆太江、刘颖、曹汐、肖巍、邢统坤、刘辉、秦日臻、林秀峰、孟令中、杨光、肖雪、郑佳佳、武斌、薛云志、王宁、徐小天、陈乐然、孙跃、王佐正、孟宪明、殷世军、胡飞雪、邸贺亮、孔维生、彭剑峰、任文奇、梁乔玲、焦继超、丁一宁。

人工智能　深度学习框架功能要求

1　范围

本文件规定了深度学习框架的功能要求，主要包括训练功能、推理功能、模型功能、算子库功能、深度学习算法功能和应用编程接口功能。

本文件适用于深度学习框架的设计、开发、验证选型和评估。

2　规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 42382（所有部分）　信息技术　神经网络表示与模型压缩

3　术语和定义

下列术语和定义适用于本文件。

3.1

深度学习　deep learning

深度神经网络学习　deep neural network learning

通过训练具有许多隐层的神经网络来创建丰富层次表示的方法。

注：深度学习是机器学习的一个子集。

[来源：GB/T 41867—2022，3.2.27]

3.2

深度学习模型　deep learning model

基于输入数据或信息生成推理或预测的计算结构。

3.3

深度学习框架　deep learning framework

提供了全面接口和功能的，用于开发训练、推理部署深度学习模型的软件工具。

3.4

计算图　computational graph

用来表示数学函数，由节点和连接构成的有向图。

注 1：节点表示数学运算，即算子。

注 2：连接表示数学运算之间的依赖关系，代表数据流动。

注 3：一个连接联通起始节点和终止节点。

[来源：GB/T 45280—2025，3.3，有修改]

3.5

张量　tensor

计算图中承载计算结果的数据变量。

3.6

算子　operator

函数的名字，或表示行动的数学或逻辑符号。

[来源：GB/T 45280—2025，3.4，有修改]

3.7

模型训练　model training

利用训练数据，基于机器学习算法，确定或改进机器学习模型参数的过程。

[来源：GB/T 41867—2022，3.2.18]

3.8

推理　inference

从给定的前提进行论证并得出结论。

注 1：在人工智能领域中，一个前提是一个事实、一个规则、一个模型、一个特征或原始数据。

注 2：术语“推理”既指过程也指结果。

[来源：GB/T 41867—2022，3.2.30]

3.9

动态图　dynamic graph

图的构建与计算同时进行，即边执行边构建的计算图执行范式。

3.10

静态图　static graph

图的构建与计算分阶段进行，即先完整构建图，再执行计算的计算图执行范式。

3.11

数据并行　data parallelism

在训练过程中，每个计算节点使用数据的一个子集进行训练，在参数更新的时候，综合不同计算节点的不同梯度信息，使用规约后的梯度数据进行参数更新的分布式训练方法。

3.12

模型并行　model parallelism

将计算图拆分成多个子图，放在不同的计算节点上运行，每个计算节点只负责子图的运算的分布式训练方法。

3.13

流水线并行　pipeline parallelism

将计算图按照层拆分多个阶段，每个阶段在不同设备上执行，从而实现类似于流水线方式的并行分布式训练方法。

3.14

重计算　re-computation

通过增加前向计算冗余以降低显存占用的一种显存优化技术。

注：在深度学习任务前向计算的过程中，对占用显存多、前向计算消耗小的结果张量，不进行存储，反向计算过程中需要使用时重新进行前向计算。

3.15

算子融合　operator fusion

将计算图中多个连续算子合并为单个算子的操作。

4　缩略语

下列缩略语适用于本文件。

AI:人工智能(Artificial Intelligence)
CPU:中央处理器(Central Processing Unit)
GPU:图形处理器(Graphic Processing Unit)
LLM:大语言模型(Large Language Model)
NPU:神经网络处理器(Neural Network Processing Unit)
ONNX:开放神经网络交换(Open Neural Network Exchange)

5 功能架构

深度学习框架功能由训练功能、推理功能、模型功能、算子库功能、深度学习算法和应用编程接口功能组成。开发者利用深度学习框架功能和组件,基于数据集训练得到深度学习模型,模型部署到实际应用中后,通过调用深度学习框架的推理接口来执行具体任务。深度学习框架功能组成见图1。

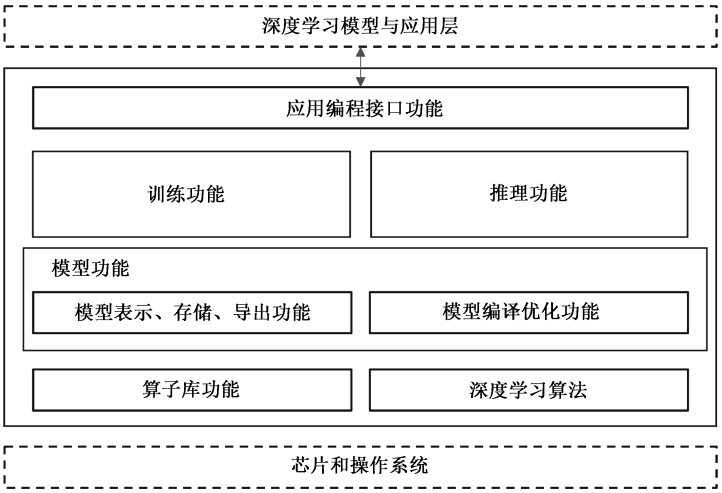


图1 深度学习框架主要功能组成

6 训练功能

6.1 数据并行功能

应具备数据集切分功能,能基于不同数据子集更新时插入梯度通信操作。

6.2 张量并行功能

应具备张量切片功能,能在拆分算子间插入通信操作。

6.3 模型并行功能

应具备模型切片功能,能在拆分模型间插入网络通信操作。

6.4 流水线并行功能

流水线并行功能包括:

a) 应具备多个AI加速设备之间的流水线并行功能;

b) 应具备将深度学习模型的层划分为多个阶段的功能,并且每个阶段是由模型中的一组连续的

层组成的。

6.5 混合并行功能

应具备数据并行、模型并行或流水线并行等混合并行的功能。

6.6 分布式训练优化算法

分布式训练优化算法包括：

a) 应具备基于集合通信架构的优化算法功能；
b) 应具备基于参数服务器架构的优化算法功能；
c) 对于稀疏激活或专家网络(MoE)模型，框架宜提供专家并行的支持。

6.7 自动并行功能

自动并行功能包括：

a) 应具备对分布式计算设备的统一逻辑拓扑表示的功能；
b) 应具备对张量在分布式计算设备中的分布状态表示的功能；
c) 应具备仅需少量(例如：10 行代码)组网改动将单卡模型自动转为包含数据并行(见 6.1)、模型并行(见 6.3)、流水线并行(见 6.4)、混合并行(见 6.5)等策略的分布式模型；
d) 应具备统一的分布式存储，并且可以在加载时转换为任意并行策略；
e) 宜具备自动并行的动态图执行和静态图执行的功能；
f) 宜具备通过静态图自动并行实现计算通信重叠(overlap)，算子融合(fusion)等优化，提升训练性能。

6.8 训练重计算功能

训练重计算功能包括：

a) 应具备通过重计算的方式，减少对显存占用的功能；
b) 应具备手工设置重计算断点的功能；
c) 宜具备自动优化计算和显存占用关系的重计算的功能。

6.9 训练循环控制功能

应支持训练循环，包括训练轮次(epoch)、训练步数(step)、验证循环的便捷管理。

6.10 混合精度训练功能

应具备低比特混合精度训练功能，能利用芯片低比特算力降低训练耗时；应支持 FP16、BF16、FP32 数据类型混合精度训练；宜支持 FP8 数据类型混合精度训练。

6.11 即时编译优化训练

宜支持通过即时编译技术对训练过程进行优化，包括但不限于动态编译并优化计算图、融合算子和适配计算硬件架构。

6.12 训练推理一体化

训练推理一体化功能包括：

a) 应具备训练过程中的在线推理验证功能；
b) 应具备训练模型到推理模型的自动转换和优化管道。

7 推理功能

7.1 计算图功能

计算图功能应包括：

a) 具备解析一种或多种深度学习框架模型格式的功能，或通过插件方式支持框架解析；
b) 具备从模型生成由一系列张量和算子组成的计算图的功能；
c) 具备为推理优化计算图功能，包括算子融合等；
d) 具备模型量化功能，至少支持 INT8 量化，宜支持 INT4、FP16 量化，对精度损失不做要求；
e) 具备为计算图转换张量的数据排布的功能；
f) 支持动态图、静态图以及动静统一功能；
g) 支持计算图可视化、计算图导出等功能。

7.2 应用编程功能接口

应用编程功能接口包括：

a) 应具备通过模型管理接口实现模型读取，模型编译优化（包括拓扑优化与模型格式转换过程）及自定义算子注册功能；
b) 应具备通过输入输出接口实现输入数据的传入和输出数据的获取功能；
c) 应具备通过推理接口实现推理实例创建、模型推理执行、神经网络推理计算和服务化部署推理计算功能；
d) 应具备通过测评接口输入测试集进行模型评测的功能；
e) 应具备通过优化接口实现模型优化，如训练和推理加速的功能，以及实现工程优化，如模型集成、流水线自动化、持续集成/持续部署（CI/CD）等的功能；
f) 宜具备通过设备管理接口实现线程管理功能，其中线程管理可用于设置与获取设备工作线程数；
g) 宜具备通过设备管理接口实现对端边设备的能耗管理，其中能耗管理可用于设置与获取设备能耗模式。

7.3 模型压缩功能

模型压缩功能包括：

a) 应具备剪枝压缩功能；
b) 应具备训练后量化功能，能将已训练模型中的浮点型张量转换为低精度整数型张量，并保持模型推理精度；
c) 应支持量化感知训练，使模型在训练阶段适配低精度量化推理；
d) 宜具备知识蒸馏、模型结构搜索等压缩功能。

8 模型功能

8.1 深度学习模型格式

深度学习模型格式包括：

a) 应定义一种与硬件平台、操作系统、编程语言无关的模型格式，具体要求应符合 GB/T 42382（所有部分）；

b) 算子定义宜具备可扩展功能，可进行算子定义扩展；
c) 模型描述中，应具备循环、条件分支的描述；
d) 宜兼容模型不同版本；
e) 宜具备模型基于 ONNX 的格式转换的功能。应支持 ONNX 1.8 及以上版本，转换后模型的算子覆盖率应不低于 95%；支持包含条件分支、循环的模型转换。

8.2 模型表示、存储、导出功能

模型表示、存储、导出功能包括：

a) 应提供模型结构和参数的在框架内的表示功能，并且具备将模型结构和参数导出和存储的功能；
b) 模型结构和参数的导出应采用与硬件平台无关的标准格式；
c) 对于静态图模式(声明式编程模式)，应提供表示、导出、存储功能，导出完整计算图功能；
d) 对于提供动态图模式(命令式编程模式)的框架，应提供获取动态图模式下模型结构的功能，对于因特殊场景导致获取失败的情况，应提供明确的报错信息；
e) 宜提供框架模型结构和参数向其他开源框架格式转换的功能；
f) 宜具备第三方工具直接读取模型结构和参数文件的功能。

8.3 模型编译优化功能

8.3.1 编译功能

宜支持跨硬件平台的神经网络编译器编译，并对计算图进行优化(如低秩分解、BatchNorm 折叠等)、自动生成针对相应硬件的高效代码。

8.3.2 计算图分析优化功能

计算图分析优化功能包括：

a) 应具备与硬件无关的优化，如表达式简化等功能；
b) 应具备与硬件相关的优化，如面向硬件的算子融合等功能；
c) 宜具备计算图自动裁剪的优化功能，根据输入、输出自动裁剪出最小依赖图并执行；
d) 宜支持统一计算图，如将动态图切分为静态子图进行编译优化。

8.3.3 执行调度功能

执行调度功能包括：

a) 应具备模型训练的任务的调度执行功能；
b) 应具备执行时选择高性能算子的功能或者策略；

注：高性能算子是指针对于底层硬件进行优化的算子，具备计算效率高的特点。

c) 宜具备日志功能；
d) 框架宜具备训练过程的监控与可视化接口。

8.3.4 动静转换功能

动静转换功能包括：

a) 应具有兼容 Python 控制流的主流动态图功能，并有将该动态图转为静态计算图网络表示以进行存储、部署、读取、训练等相关能力；
b) 宜具备转化后的静态图表示在 C++等其他非 Python 语言环境下部署；C++ 部署接口应提

供头文件与动态链接库(.so/.dll),支持同步 / 异步推理调用;接口应包含模型加载、推理执行、结果获取等核心函数,函数参数与返回值类型应明确(如张量形状用 int 数组表示、数据类型用枚举类型表示);

c) 宜具备转化后的静态图表示可根据计算图全局信息进行静态图优化功能,如 fusion(融合)、冗余算子去除、量化等优化方式。

9 算子库功能

算子库功能包括:

a) 具备基础算子集,支持通过基础算子组合方式定义其他算子;
b) 算子能在多种设备上运行,如 CPU、GPU、NPU 等;
c) 具备可广播能力的算子接口,广播机制允许形状不同的张量进行逐元素运算,通过自动扩展较小张量的形状使其兼容,无需复制数据,提升代码简洁性和计算效率;
d) 具备转换算子功能,转换算子是一种特殊的算子,用于转换张量的数据类型与格式等信息,使得图中上下游节点能被正常处理;
e) 提供详细算子功能说明和使用方式展示;
f) 具备算子注册接口,具备 Python 或 C++新增算子功能;
g) 具备算子动态加载功能;
h) 应具备硬件抽象层(HAL)接口,支持新型硬件的快速接入;
i) 应具备异构调度器,支持跨不同类型硬件的动态负载均衡;
j) 宜预留量子-经典混合计算接口;
k) 应具备硬件无关的中间表示(IR),便于不同硬件后端的优化。

10 深度学习算法

深度学习框架应具备对以下深度学习算法的训练和推理功能:

a) 计算机视觉类算法,包括但不限于用于图像分类、目标检测、图像分割、视频分类、关键点检测等任务的算法;
b) 语音类算法,包括但不限于用于语音识别、语音合成等任务的算法;
c) 自然语言处理类算法,包括但不限于文本分类、机器翻译等;
d) 智能推荐类算法,包括但不限于内容理解、候选集召回、结果排序等;
e) 图神经网络算法;
f) 支持 LLM、扩散模型(diffusion)等大模型类算法;具备高效的注意力机制优化,应具备长序列处理能力,支持不低于 100 000 个词元的上下文输入长度;
g) 强化学习类算法。

11 应用编程接口功能

应用编程接口功能如下。

a) 应提供数据处理、模型定义、模型训练、模型评估、模型推理等接口。
b) 应具备内存/显存优化相关功能以及相关接口。
c) 应具备动态构建算法网络功能。
d) 宜具备静态构建算法网络功能。

e） 应至少支持声明式或命令式编程中的一种。

f） 应具备分布式训练功能。

g） 应具备基于动态控制流的组网，包括条件分支、循环嵌套。

h） 宜具备带控制流的动态图转换为静态图，具备用静态图进行训练、部署。

i） 应具备张量、稀疏张量等数据结构，应具备整数、浮点数等数据类型。宜具备复数数据类型。

j） 应具备张量操作功能，宜具备稀疏神经网络组网、损失函数定义、优化算法、参数更新等功能。

k） 应具备高性能数据读取功能，包括：

1） 多线程或多进程数据读取；

2） 多段流水线并行的数据处理机制。

l） 应具备模型存储、载入、管理接口，具备模型恢复训练功能。

m） 宜具备动态图和静态图之间的转换功能。

n） 宜具备动静态图混合执行功能。

o） 宜具备自动混合精度训练功能。

p） 宜具备对已有模型进行修改、优化、查询等二次编辑能力相关接口。

参 考 文 献

[1] GB/T 41867—2022 信息技术 人工智能 术语
[2] GB/T 45280—2025 人工智能 异构人工智能加速器统一接口