ICS 35.060
CCS L 74

中华人民共和国国家标准化指导性技术文件

GB/Z 299—2026

人工智能操作系统通用技术要求

General technical requirements for artificial intelligence operating system

2026-09-24 发布

国家市场监督管理总局
国家标准化管理委员会 发布

目　　次

前言 …… Ⅲ
引言 …… Ⅳ
1　范围 …… 1
2　规范性引用文件 …… 1
3　术语和定义 …… 1
4　缩略语 …… 2
5　人工智能操作系统框架 …… 2
6　内核要求 …… 2
7　AI运行库要求 …… 3
8　AI服务要求 …… 3
8.1　感知服务 …… 3
8.2　交互服务 …… 3
8.3　模型管理 …… 4
8.4　智能体管理 …… 4
8.5　工具管理 …… 4
8.6　技能管理 …… 5
8.7　上下文管理 …… 5
8.8　记忆管理 …… 5
8.9　跨设备协同 …… 6
8.10　数据服务 …… 6
9　系统智能体要求 …… 6
9.1　智能化能力 …… 6
9.2　调用能力 …… 7
9.3　系统管理能力 …… 8
10　智能体开发套件要求 …… 8
11　AI安全要求 …… 8
11.1　权限管理 …… 8
11.2　身份鉴别 …… 8
11.3　智能体运行安全 …… 9
11.4　工具安全 …… 9
11.5　技能安全 …… 9
11.6　沙箱安全 …… 9

11.7 模型安全 ……9
11.8 行为审计 ……9
参考文献 ……11

前　言

本文件为规范类指导性技术文件。

本文件按照GB/T 1.1—2020《标准化工作导则　第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由全国信息技术标准化技术委员会(SAC/TC 28)提出并归口。

本文件起草单位：中国电子技术标准化研究院、华为终端有限公司、中兴通讯股份有限公司、小米通讯技术有限公司、统信软件技术有限公司、天翼云科技有限公司、OPPO广东移动通信有限公司、麒麟软件有限公司、中移(苏州)软件技术有限公司、维沃移动通信有限公司、荣耀终端股份有限公司、北京兴云数科技术有限公司、上海文鳐信息科技有限公司、南京大学、成都理工大学、深城交科技集团股份有限公司、中国船舶集团有限公司第七一六研究所、北京凝思软件股份有限公司、北京健康有益科技有限公司、福建汇思博数字科技有限公司、鼎桥技术有限公司、元心信息科技集团有限公司、联想(北京)有限公司、招商局重庆交通科研设计院有限公司、上海师范大学天华学院、北京东土科技股份有限公司、青岛酷特智能股份有限公司、云从科技集团股份有限公司、政达研学(雄安)科技有限公司、海光信息技术股份有限公司、深圳开鸿数字产业发展有限公司、上海零数众合信息科技有限公司、海信视像科技股份有限公司、福建省标准化研究院、北京百度网讯科技有限公司、深圳润迅人工智能科技有限公司、湖南麒麟信安科技股份有限公司、星尘智能(深圳)人工智能科技股份有限公司、上海超多元子人工智能科技有限公司、深圳市证通电子股份有限公司、北京交通大学、中科慧拓(北京)科技有限公司、公安部第三研究所、中移(杭州)信息技术有限公司、浦江国家实验室、普华基础软件股份有限公司、浙江数智交院科技股份有限公司、中铁建工集团有限公司、中科海微(北京)科技有限公司、国家工业信息安全发展研究中心、进迭时空(北京)科技有限公司、北京宝兰德软件股份有限公司、北京国科环宇科技股份有限公司、浪潮计算机科技有限公司、中国人民解放军32008部队、上海新榜信息技术股份有限公司、广州哆啦科技有限公司。

本文件主要起草人：王威伟、焦廉洁、苗宗利、董建、杨磊、张希璐、史浩、孟眉、刘东、胡冲、李建慧、王磊、马承青、唐杨、姜少涛、李腾、郭爽、张胜举、高立发、徐曼、王键、谢南淦、徐立锋、刘海涛、李鹤、刘铭然、李根、张超、李永强、曹宇琼、李辰淑、高歌、李晨、商家奇、刘小锐、仲凯韬、王楚豫、程晗蕾、许建荣、孔祥营、李晓宇、李宇欣、邱熠龙、黄晋飞、陈鑫、郭一平、骆中斌、郑宁、梁华煜、李海滨、杨显森、苏蕾权、展恩果、陈强、兰春嘉、纪开虎、李海晏、孙鑫洋、隋成龙、赵敏敏、魏遵博、夏梦、曾培恒、汪群博、张科、宋好好、江文则、裴芝林、梁浩、王益维、生兆亮、公衍林、许智鑫、杨庄媛、詹年科、刘志立、刘圣金、唐乐乐、沈涓、刘海军、梁天善、冯洋、王森、黄浩然、李斯琦、叶青、吕博、周翔、张伟琦、杨珍、张宏伟、董睿、胡晴鹤、石勇、杨文涵、夏瑞麟、安佳勇、曹思玮、肖旭、王和俊、胡尊凤、赵博、周鑫羽、吕皓。

引　言

当前，随着大模型、智能体等人工智能技术加速突破，面向智能终端和个人应用场景的人工智能操作系统市场迎来前所未有的发展机遇。人工智能正驱动智能终端操作系统加快向人工智能操作系统演进，在继承CPU、内存、存储等传统硬件资源抽象和进程管理能力的基础上，将AI算力、模型、智能体、工具、技能等作为新型管理对象，面向终端用户提供面向智能任务的原生调度与协同能力，推动操作系统从“资源管理者”向“智能调度中枢”跃升，其角色定位、能力边界与生态逻辑正在被重新定义。然而，人工智能操作系统技术及标准化工作处于起步阶段，业界对其内涵外延、功能架构、演进方向尚未形成共识，亟需强化行业引导，防控安全风险，促进操作系统产业高质量发展。

操作系统在向人工智能操作系统演进中，除了具备传统操作系统的基础能力外，还具备自底向上的AI能力。本文件不定义传统操作系统的基础能力，仅对具备人工智能特性的关键能力进行规范，移动通信终端、微型计算机、便携式微型计算机、平板式微型计算机、可穿戴设备、车载终端等的操作系统功能根据自身硬件能力进行相应调整。本文件与GB/Z 300配合使用。

人工智能操作系统通用技术要求

1 范围

本文件确立了面向智能终端和个人应用场景的人工智能操作系统框架，规定了内核、AI运行库、AI服务、系统智能体、智能体开发套件和AI安全的要求。

本文件适用于面向智能终端和个人应用场景的人工智能操作系统设计、开发、测试等，也为智能终端系统及智能化应用的设计、开发、测试提供参考。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/Z 300 人工智能操作系统权限管理要求

GB/T 41867 信息技术 人工智能 术语

3 术语和定义

GB/T 41867界定的以及下列术语和定义适用于本文件。

3.1

操作系统 operating system

用于管理硬件资源、控制程序运行、提供人机界面，并为应用软件提供支持的一种系统软件产品。

[来源：GB/T 36630.3—2018，3.1，有修改]

3.2

人工智能操作系统 artificial intelligence operating system

使用人工智能技术进行资源管理、任务调度和安全管理，并提供智能体等智能化软件所需运行环境的操作系统。

注：人工智能操作系统各项功能的实现以硬件为条件，当硬件具备相应能力时，人工智能操作系统实现对应功能。

3.3

智能体 AI agent

感知环境，并主动采取行动以实现特定目标的实体。

注1：本文件中的智能体特指人工智能智能体，一般为软件系统。

注2：具备感知、认知、执行、记忆、学习等功能。

[来源：GB/Z 185.1—2026，3.1，有修改]

3.4

系统智能体 system AI agent

人工智能操作系统的组成部分，具备任务分发、资源调度、系统管理等功能的智能体。

3.5

工具 tool

被按需调用，用于执行特定操作或获取特定信息的软件功能单元。

3.6

技能　skill

由指令、元数据、资源等组成的可复用能力单元，供智能体按需加载和调用。

4　缩略语

下列缩略语适用于本文件。

AI：人工智能（Artificial Intelligence）

CPU：中央处理器（Central Processing Unit）

GPU：图形处理器（Graphics Processing Unit）

IDE：集成开发环境（Integrated Development Environment）

I/O：输入/输出（Input/Output）

NPU：神经处理单元（Neural Processing Unit）

ONNX：开放神经网络交换（Open Neural Network eXchange）

ReAct：推理行动（Reasoning Acting）

SDK：软件开发工具包（Software Development Kit）

5　人工智能操作系统框架

人工智能操作系统框架包括内核、AI运行库、AI服务、系统智能体、智能体开发套件、AI安全等，框架图见图1。

a）　内核：人工智能操作系统的中枢，负责异构算力、存储、网络等硬件管理与资源调度；

b）　AI运行库：提供底层库函数与执行环境，供智能体与应用调用；

c）　AI服务：人工智能操作系统的核心能力层，对于共享资源统一以服务声明方式对外暴露，提供感知、交互、模型等服务，支撑智能体运行与跨设备协同；

d）　系统智能体：统筹系统级任务，具备智能化、调用及管理等能力；

e）　智能体开发套件：提供创建、调试与部署智能体所需工具及接口的开发环境；

f）　AI安全：面向人工智能操作系统各层提供安全保障，保障数据、模型及系统运行的安全性。

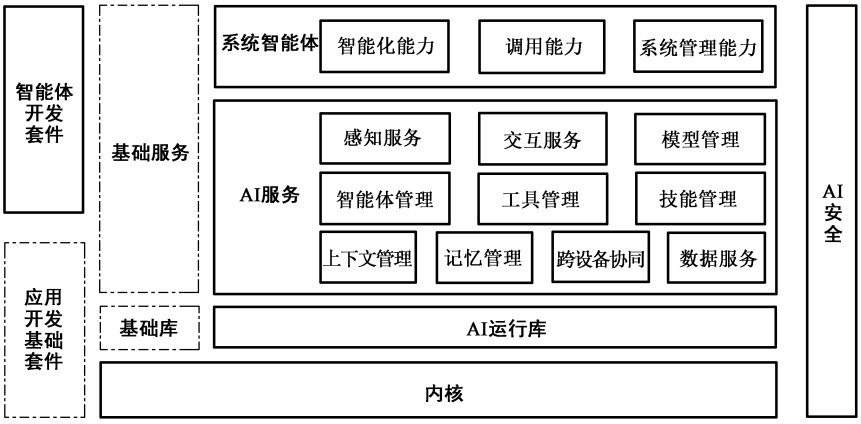


图1　人工智能操作系统框架

6　内核要求

内核符合下列规定：

a） 应提供对异构算力设备、存储、通信、传感器的硬件抽象与驱动管理功能，通过统一硬件访问接口，提供硬件状态查询、资源分配、任务调度等功能；
b） 应提供轻量级隔离功能，支持硬件虚拟化隔离，及细粒度的资源配额管理；
c） 应提供内核空间隔离、内存保护、驱动完整性校验等安全机制；
d） 应支持基于硬件信任根的可信启动与度量，对内核、模型文件及关键组件进行完整性校验；
e） 应提供跨进程通信与设备互联功能；
f） 应提供动态电源管理机制，根据任务实时负载、优先级、资源占用、供电模式、设备温度等，动态调节设备工作状态；
g） 宜提供内核模块按需动态加载功能，支持按场景动态加载异构算力驱动框架及运行时所需的组件等；
h） 宜提供面向异构算力的统一内存管理与跨域零拷贝功能，支持异构共享内存的动态切分与回收，对于非统一内存架构，提供内存同步与数据迁移接口；
i） 宜提供支持并发访问与异步I/O的文件系统，可通过数据预取与缓存加速机制，支撑模型文件、运行数据等快速加载与访问；
j） 宜提供多模型并发执行时的算力和内存资源调度功能，按优先级和运行状态动态分配资源，优先调度时延敏感型AI任务；
k） 宜支持机密计算，可提供基于身份的细粒度动态访问控制功能；
l） 宜提供确定性网络传输和流量控制功能。

7 AI运行库要求

AI运行库与内核驱动框架之间通过明确定义的边界接口进行通信，符合下列规定：
a） 应支持常用神经网络交换格式（如ONNX格式等）的模型解析与推理执行；
b） 应支持面向CPU、GPU、NPU等异构算力的算子库、模型运行时；
c） 应具备面向语言模型的推理运行时，包括分词预处理、动态批处理、键值缓存管理、显存优化、并发请求调度等机制；
d） 应提供向量存储与检索的运行时，包括向量的高效存储、索引构建及重建（如基于图的索引、基于量化的倒排索引等）、相似度检索、增量更新等功能；
e） 应支持任务分解、计划编排与执行，可采用ReAct或工作流等方式，并支持智能体间的协同；
f） 端侧资源受限场景下宜支持轻量化模型加载、推理、执行。

8 AI服务要求

8.1 感知服务

应通过外联设备、内外部传感器、数据采集模块、识别模块或互联网等的接口，感知、采集、识别用户生物特征、用户输入内容、用户行为、硬件信息、软件信息、环境信息等输入，提供相应感知服务。

8.2 交互服务

交互服务应符合下列要求：
a） 提供多模态交互处理接口，支持应用、智能体或外部系统调用，输出文本、语音、图像、视频、触觉反馈、动作指令、设备控制信号等，并根据设备能力与交互场景自适应调整输出形式；
b） 根据对话、用户反馈、任务结果等，对交互策略进行优化；

c） 具备交互过程的状态管理能力；
d） 提供交互资源的调度机制，根据场景或优先级等进行动态响应。

8.3 模型管理

模型管理符合下列规定：
a） 应具备模型推理指标分析功能，包括推理时延等指标；
b） 应具备云侧模型服务凭证的安全存储功能，在请求云侧模型服务时，按需将凭证注入请求中；
c） 宜提供统一的模型服务接口，提供端侧模型信息注册查询、便捷部署、升级管理等功能；
d） 宜具备模型路由机制，根据任务需求、模型功能、实例负载、可用性、预设路由策略等，自动将推理请求路由至相应的模型实例。

8.4 智能体管理

智能体管理符合下列规定。
a） 智能体管理的基本规定包括：
1） 应提供智能体描述信息的声明、查询等功能，如智能体标识、名称、版本、描述、提供方、默认输入类型、默认输出类型、技能、权限声明；
2） 应提供智能体安装功能，包括安装包解析、完整性校验、安全检查等；
3） 应提供智能体卸载功能，卸载时终止该智能体的运行实例并清除服务注册信息，经用户确认后清除本地存储数据；
4） 宜与外部智能体公共服务平台互联互通，并提供信息查询、核验等功能。
b） 应提供智能体运行管理功能，并符合下列要求：
1） 提供智能体间协作机制；
2） 提供智能体发现机制，支持智能体按能力描述进行查找与匹配；
3） 具备智能体运行时的资源隔离功能；
4） 按任务类型、前后台状态等提供智能体任务调度机制，保障高优先级任务；
5） 提供智能体等运行实例的状态监测、异常告警、恢复等功能；
6） 提供暂停或结束智能体运行的功能，结束后回收运行时资源；
7） 提供事件总线机制，供智能体、工具、技能等通过发布、订阅等方式，交换相关事件信息。

8.5 工具管理

工具管理符合下列规定。
a） 工具管理的基本规定包括：
1） 应提供工具声明等功能；
2） 工具描述应包括名称、版本、功能说明、输入参数、输出参数、调用方式、权限声明等信息；
3） 应提供工具清单管理功能，以及工具信息的查询、增加、更新、注销等功能；
4） 宜将常用能力进行工具化封装，供其他应用、智能体调用，如媒体摄录、通话、短信、日历、时钟、备忘录、相册、浏览器、应用商店等；
5） 宜将外联设备的操作能力进行工具化封装，供其他应用、智能体调用，如智能家居控制、短距通信设备、打印扫描设备、显示投屏设备、可穿戴设备等。
b） 工具调用管理的规定包括：
1） 应提供统一的访问接口进行工具调用；
2） 应提供工具调用链路记录，包括调用时间、请求参数、返回结果、执行耗时及调用方身份标识等；

3） 宜限制工具调用的资源使用上限和执行超时阈值。

8.6 技能管理

技能管理符合下列规定。

a） 技能管理的基本规定包括：
   1） 应提供技能的下载、加载、查询、更新、删除等功能；
   2） 宜具备技能的版本升级和管理功能；
   3） 技能加载宜提供能力描述、权限清单、数据访问范围等；
   4） 宜对技能依赖关系进行声明与校验，包括与运行环境、模型、智能体、工具、其他技能等的依赖关系。

b） 技能调用管理的规定包括：
   1） 应提供技能的发现与按需激活等功能；
   2） 应提供技能调用记录；
   3） 宜提供技能自进化机制。

8.7 上下文管理

上下文管理符合下列规定：

a） 应具备上下文构建功能，支持将会话历史、环境感知数据、提示词、模板等，按需组织为结构化消息序列；

b） 应实现上下文窗口的动态容量管理，依据模型能力、任务需求等，对上下文总量按词元进行计量与约束，在窗口受限时进行自动裁剪，并记录裁剪日志；

c） 应具备上下文语义摘要、压缩、优化等功能，包括会话历史关键信息提取、冗余信息剔除等；

d） 应提供上下文数据生存周期管理机制，包括上下文信息的存储、归档与清除；

e） 应具备上下文访问控制与安全隔离功能，防止跨用户、跨智能体、跨会话越权访问；

f） 应具备上下文状态保存与恢复功能；

g） 宜具备长周期上下文的保持功能，支持智能体在跨会话、跨任务周期中继承并复用关键上下文信息；

h） 宜提供文本、音频、视频、图像、传感器数据等多模态上下文的语义关联与协同；

i） 宜提供外部知识库、数据库的动态检索功能。

8.8 记忆管理

记忆管理符合下列规定：

a） 应具备多模态数据在端侧进行记忆融合处理的功能；

b） 应具备记忆数据的预处理、分析、合并等功能，形成记忆标签库并分类管理；

c） 应提供记忆安全沙箱隔离机制，为不同应用、智能体分配独立记忆空间，进行隔离执行，防止跨应用数据泄露；

d） 应提供记忆数据生存周期管理机制；

e） 应支持按系统预设或用户配置数据失效规则，自动清除过期记忆数据；

f） 删除记忆时，应同步清除全部关联数据；

g） 应对共享的记忆数据实施脱敏处理，降低用户身份被关联识别与逆向推断的风险；

h） 应对记忆实施分级管理（如短期、中期、长期记忆），明确记忆的来源、用途、敏感等级、留存依据等，不同级别记忆采用差异化存储和访问控制策略；

i） 宜提供记忆数据查询、删除、导出等功能。

8.9 跨设备协同

跨设备协同符合下列规定：

a） 应具备多链路聚合与智能路由功能，支持异构网络自适应，实现在复杂环境下的多设备连接和跨网络切换；

b） 应提供跨设备能力的发现与分布式注册机制，根据跨设备的原子化能力描述构建设备能力模型，保障动态拓扑下服务的同步与状态一致性；

c） 应实现设备双向鉴别；

d） 应仅共享必要数据并脱敏；

e） 宜支持加密通信协议；

f） 宜支持端云协同推理，将推理任务分发至端侧和云侧协同执行；

g） 宜支持分布式推理，在多设备间分发任务协同执行。

8.10 数据服务

数据服务宜符合下列规定：

a） 支持应用、智能体、用户自主配置数据接入、开放策略等，如按开放范围、开放频次、有效时间、访问主体等进行配置；

b） 具备跨应用沙箱的数据汇集、数据存储、语义加工与受控流转等功能；

c） 支持不同应用、智能体之间交换数据和任务上下文。

9 系统智能体要求

9.1 智能化能力

9.1.1 感知

应具备多模态感知功能，感知并获取用户信息、终端信息、环境信息等多维度数据，符合下列规定：

a） 应支持对用户多模态输入信息进行理解，并关联跨模态上下文语义；

b） 应具备对所在设备运行状态的感知功能；

c） 宜具备对跨设备任务执行状态的感知功能；

d） 宜具备对用户所处环境及跨空间场景连续性的感知功能。

9.1.2 认知

认知符合下列规定：

a） 应具备模糊语义理解与复杂意图识别功能，从用户的自然表达或行为模式，结合上下文、设备状态及环境等，推断其潜在需求；

b） 应具备多步骤任务自主规划功能，将用户的复合意图需求自动拆解为可行的操作序列；

c） 宜对思考决策过程进行记录。

9.1.3 执行

执行应符合下列要求：

a） 具备任务状态查询功能，任务状态包括待执行、执行中、暂停、已完成、异常中断、超时等；

b） 支持用户暂停、继续、终止或重启任务；

c） 支持对系统常用工具的操作，如记事、设置系统日历、拨打电话、发送短信、设定闹钟、设置通讯录等；
d） 具备自动化执行用户指令的功能；
e） 具备跨应用、智能体、工具等的串联操作功能，在任务流程中依次调用多个应用、智能体或工具；
f） 提供任务触发功能，在特定条件（如特定时间等）满足时，自动执行用户预设任务；
g） 具备多任务执行功能，在不干扰用户当前操作的前提下后台独立运行，任务完成或需要用户介入时主动提示用户；
h） 记录任务的操作步骤与执行结果。

9.1.4 记忆

应具备短期记忆、长期记忆功能。

9.1.5 学习

宜具备持续学习功能，根据用户反馈、环境反馈、外部知识更新、外部辅助数据等，通过外部优化或自我优化等方式，对任务策略、工具选择等进行动态调整。

9.2 调用能力

9.2.1 模型调用

模型调用符合下列规定：
a） 应支持模型配置；
b） 宜提供端侧模型调用模式，用户隐私数据优先在端侧推理，仅在必要时经用户授权后上传云侧。

9.2.2 工具调用

工具调用符合下列规定：
a） 应理解用户意图，生成工具调用需求；
b） 应提供单工具调用、多工具链式编排等功能；
c） 工具调用失败时应自动重试或终止调用；
d） 工具调用流程和数据格式参考GB/Z 185.7。

9.2.3 技能接入

技能接入应符合下列要求：
a） 提供技能接入框架，实现技能自动匹配或按需接入；
b） 提供技能的渐进式加载功能，启动时仅加载技能的名称与描述等元信息用于路由匹配，触发时加载技能正文指令，执行时按需加载脚本与资源。

9.2.4 智能体间协作

应提供与其他智能体的协作机制，并应符合下列要求：
a） 将任务分解并分配给不同的应用、智能体并行或串行执行，对任务分配路径、任务优先级等进行决策和调度；
b） 接收其他智能体任务协作。

9.2.5 跨设备调用功能

宜提供跨设备调用功能，如提供，跨设备调用功能符合下列规定：

a） 应支持与其他设备的智能体进行协作，包括任务决策、任务执行、状态互通等；
b） 宜具备跨设备任务的决策、分发与协调功能，将任务分配到不同设备协同完成；
c） 宜支持跨设备的任务迁移。

9.3 系统管理能力

应提供系统管理功能，并应符合下列要求：

a） 支持用户通过自然语言指令进行系统设置，包括开关网络、开关蓝牙、调节音量、调节亮度、管理文件等；
b） 具备系统资源管理功能，如应用管理、后台进程管理等，并提供异常阻断机制；
c） 具备系统运行状态监测功能，如系统资源消耗、应用运行状态、智能体运行状态等，系统运行状态异常时提示用户。

10 智能体开发套件要求

智能体开发套件符合下列规定。

a） 应提供统一的智能体打包、签名与发布格式，包括元信息、依赖声明、入口代码、资源配置等。
b） 应具备智能体的版本管理功能，并支持运行环境与依赖管理。
c） 应提供智能体创建功能，支持通过提示词配置、工具选择、流程编排等方式创建。
d） 应提供模型适配器，支持接入不同场景的模型。
e） 宜提供面向智能体的开发、测试、调试、仿真、部署、监控等软件开发功能，及功能行为定义、会话与状态管理等功能：
   1） 提供技能定义模板、工程构建与发布功能，支持技能能力声明、行为规则配置、业务逻辑编排、数字签名等；
   2） 提供工具定义模板、打包构建及数字签名校验机制，支持工具能力描述、调用逻辑配置、最小权限声明等；
   3） 提供测试工具，如单元测试、集成测试、仿真测试、性能测试、安全测试等工具。
f） 宜支持智能体与前端组件之间交互协议，实现与网页端、移动端、IDE 等多种客户端或前端组件的交互通信。
g） 宜提供自然语言编程工具，支持对话历史追踪、上下文管理、跨会话长期偏好记忆。
h） 宜提供多智能体编排功能，支持串行、并行、条件分支、循环等多种编排方式。
i） 宜提供多编程语言的 SDK。

11 AI安全要求

11.1 权限管理

权限管理应符合 GB/Z 300 的规定。

11.2 身份鉴别

身份鉴别宜符合下列规定：

a） 支持口令、图形、图案、生物特征、外部硬件令牌或数字证书等多种身份鉴别方式；
b） 采用人工智能技术实现用户身份鉴别和多用户动态切换。

11.3 智能体运行安全

智能体运行安全应符合下列要求：
a） 提供智能体访问行为管理机制，如根据访问数据敏感度、智能体行为风险等进行分级分类，并实施相适应的访问控制策略；
b） 具备恶意指令、诱导泄露、权限绕过等攻击行为的识别、防护和处置功能，对异常指令进行检测、拦截、降级或提示用户确认；
c） 对智能体调用部署在操作系统的工具和技能的请求进行安全策略校验，防止智能体执行未经用户授权、违反系统安全策略等行为；
d） 跨端智能体之间的通信采用安全传输协议，防止恶意攻击和数据窃取。

11.4 工具安全

工具安全符合下列规定：
a） 应对部署在操作系统上工具的调用指令进行识别、隔离等；
b） 应对工具危害操作系统安全或用户数据安全的行为进行处置，可自动提示用户或终止工具运行。

11.5 技能安全

技能安全符合下列规定：
a） 应校验技能完整性、来源可信性、依赖安全性，校验通过后技能进入本地安装目录或运行目录，校验失败时拒绝安装并提示用户确认；
b） 应提供技能行为监测机制，发现异常行为时可暂停技能执行并提示用户处置。

11.6 沙箱安全

应提供沙箱安全隔离环境，并应符合下列要求：
a） 支持对智能体调用或生成的相关脚本、代码等隔离运行；
b） 沙箱会话结束时，清除沙箱内的临时数据和运行状态。

11.7 模型安全

模型安全符合下列规定：
a） 应对模型输入、模型输出、工具调用参数的敏感信息进行识别与脱敏处理，防止个人信息、身份凭证、密钥、商业秘密等敏感数据泄露；
b） 应支持对下载或导入的模型文件进行完整性校验；
c） 应支持端侧推理模型文件的加密存储；
d） 应对模型生成内容进行检查，记录风险类别、处置方式、输出摘要、相关上下文等信息，支持事后追溯、统计分析和策略优化；
e） 当模型输出触发安全风险时，可采取拒绝生成、降级回答、内容改写、用户确认、人工审核、阻断输出或安全告警等处置措施。

11.8 行为审计

行为审计应符合下列要求：

a） 具备审计功能，对系统管理、工具调用、技能接入、资源访问等操作输出审计日志；
b） 记录操作主体、操作对象、操作时间、操作内容、操作结果等信息，涉及用户敏感信息的采取脱敏措施；
c） 记录用户授权的执行过程、风险提示等；
d） 审计日志支持防篡改、防删除和完整性校验。

参 考 文 献

[1] GB/Z 185.1—2026 人工智能 智能体互联 第1部分:总体架构
[2] GB/Z 185.2 人工智能 智能体互联 第2部分:身份码
[3] GB/Z 185.3 人工智能 智能体互联 第3部分:身份管理
[4] GB/Z 185.4 人工智能 智能体互联 第4部分:智能体描述
[5] GB/Z 185.5 人工智能 智能体互联 第5部分:智能体发现
[6] GB/Z 185.6 人工智能 智能体互联 第6部分:智能体交互
[7] GB/Z 185.7 人工智能 智能体互联 第7部分:智能体工具调用
[8] GB/T 25655—2010 信息技术 中文Linux桌面操作系统技术要求
[9] GB/T 34978 信息安全技术 移动智能终端个人信息保护技术要求
[10] GB/T 34980.1 智能终端软件平台技术要求 第1部分:操作系统
[11] GB/T 35273 信息安全技术 个人信息安全规范
[12] GB/T 36630.3 信息安全技术 信息技术产品安全可控评价指标 第3部分:操作系统
[13] GB/T 45288.1 人工智能 大模型 第1部分:通用要求
[14] GB/T 46903 数据安全技术 个人信息保护合规审计要求
[15] 全国人民代表大会常务委员会.中华人民共和国网络安全法[L].北京:中国法治出版社,2025.